BLG447 GÖRÜNTÜ İŞLEME DERSİ FİNAL PROJESİ RAPOR

Diz Osteoartriti X-Işını Görüntülerinin Doku ve Şekil Öznitelikleri ile Otomatik Sınıflandırılması: Kapsamlı Bir Radyomik Analiz ve Makine Öğrenmesi

HAZIRLAYAN:

Neşe Rihani-220404906
Eda Şimşek-220404041
Begüm Koyuncu-220404010

Bilgisayar Mühendisliği(Türkçe)

1. Giriş ve Proje Amacı

Diz osteoartriti (OA), eklem kıkırdağının dejenerasyonu, eklem boşluğunun daralması ve kemik kenarlarında osteofit adı verilen kemik çıkıntılarının oluşumu ile karakterize edilen kronik bir eklem hastalığıdır. Dünya genelinde özellikle yaşlı popülasyonda engelliliğin en yaygın nedenlerinden biri olan bu durum, hastaların hareket kabiliyetini kısıtlamakta ve yaşam kalitesini önemli ölçüde düşürmektedir. Hastalığın erken evrelerde teşhis edilmesi, tedavi süreçlerinin planlanması ve eklem hasarının ilerlemesinin yavaşlatılması açısından kritik bir öneme sahiptir. Klinik teşhis süreçlerinde radyoloji uzmanları, X-ışını görüntülerini Kellgren-Lawrence (KL) evreleme sistemine göre değerlendirerek hastalığın şiddetini belirlemektedir. Ancak, bu değerlendirme süreci hekimin tecrübesine bağlı olarak subjektiflik içerebilmekte ve düşük gözlemciler arası güvenilirlik oranları sergileyebilmektedir.

Bu çalışma Diz X-ışını görüntülerinden doku, şekil ve frekans tabanlı özniteliklerin çıkarılması ve makine öğrenmesi algoritmaları ile otomatik olarak sınıflandırılması sistemini detaylandırmaktadır. Çalışma kapsamında, Gri Seviye Birliktelik Matrisi (**GLCM**), Yerel İkili Desenler (**LBP**), Yönelimli Gradyanların Histogramı (**HOG**), Ayrık Dalgacık Dönüşümü (**DWT**), Hızlı Fourier Dönüşümü (**FFT**) ve **Gabor** filtreleri gibi ileri düzey öznitelik çıkarım yöntemleri kullanılmış; elde edilen veriler Weka platformunda kapsamlı bir şekilde analiz edilmiştir.

2. MATERYAL ve YÖNTEM (METODOLOJİ)

2.1 Proje Ekibi ve İş Dağılımı

Proje, üç kişilik ekip tarafından eşit iş yükü ilkesiyle yönetilmiş ve aşağıdaki görev dağılımı uygulanmıştır.

Ekip Üyesi	Temel Sorumluluk Alanı
Neşe Rihani	kNN ve Random Forest Algoritması Uygulamak, Kod ve Rapor.
Begüm Koyuncu	AdaBoost+48 J48 Uygulamak, Feature Selection ve Karşılaştırma Tablolarının Oluşturulması, Rapor.
Eda Şimşek	SVM MLP Uygulamak, Sunum Hazırlaması ve Rapor.

2.2 Veri Seti Analizi ve Hazırlık Süreci

Final projesi için seçilen veri seti, Kaggle platformunda paylaşılan ve Shashwat Tiwari tarafından derlenen "**Knee Osteoarthritis Dataset with Severity Grading**" koleksiyonudur. Bu veri seti, binlerce diz X-ışını görüntüsünü içermekte ve her bir görüntü uzmanlar tarafından KL evrelerine göre etiketlenmiş durumdadır.

2.2.1. Veri Seti Yapısı ve Dağılımı

Veri seti, eğitim (train), doğrulama (val) ve test alt klasörlerinden oluşmaktadır. Her ana klasörün altında, KL evrelerini (0, 1, 2, 3, 4) temsil eden klasörler bulunmaktadır. Analiz sürecinde, sistemin ayırt edici gücünü test etmek amacıyla bu beş evreli yapı, "no_OA" (Evre 0) ve "OA" (Evre 1, 2, 3, 4) şeklinde ikili (binary) sınıflandırma yapısına dönüştürülmüştür. Bu yaklaşım, sistemin sağlıklı bireyler ile herhangi bir düzeyde osteoartrit belirtisi gösteren hastaları birbirinden ayırma yeteneğini optimize etmeyi amaçlamaktadır.

2.2.2. Görüntü Okuma ve Sınıf Eşleştirme Rasyoneli

Geliştirilen Python betiği, veri seti klasör yapısını otomatik olarak tarayarak görüntüleri ve etiketleri eşleştirmektedir. "0" etiketli klasördeki görüntüler "no_OA" olarak işaretlenirken, diğer tüm evreler (1-4) "OA" kategorisi altında toplanmıştır. Bu birleştirme rasyoneli, tıbbi uygulamalarda tarama (screening) sistemlerinin temel prensibi olan "hastalığın varlığını saptama" hedefine hizmet etmektedir.

3. Görüntü Ön İşleme ve ROI Stratejileri

X-ışını görüntüleri, çekim tekniği ve cihaz farklılıkları nedeniyle gürültü, dengesiz aydınlatma ve düşük kontrast gibi sorunlar barındırabilir. Bu faktörler, öznitelik çıkarım aşamasında yanlış verilere yol açabileceği için kapsamlı bir ön işleme hattı kurulmuştur.

3.1. Yumuşak ROI (Region of Interest) Uygulaması

X-ışını görüntüsünün tamamı diz eklemi dışındaki alanları, cihaz üzerindeki metal etiketleri veya yumuşak dokuları içerir. Bu bölgeler sınıflandırma için anlamsızdır ve öznitelik setine gürültü ekler. Bu nedenle, görüntünün merkez bölgesine

odaklanan bir "Soft ROI" yöntemi uygulanmıştır. Görüntünün yükseklik ve genişlik eksenlerinden belirli oranlarda kırpma yapılarak, eklem bölgesinin korunması ve kenar gürültülerinin azaltılması sağlanmıştır.

3.2. Kontrast Artırma ve Normalizasyon (CLAHE)

Diz eklem boşluğundaki kıkırdak hasarını ve osteofitleri daha belirgin hale getirmek için Kontrast Sınırlı Adaptif Histogram Eşitleme (CLAHE) yöntemi kullanılmıştır. CLAHE, global histogram eşitlemenin aksine, görüntüyü küçük bloklara ayırarak yerel kontrastı artırır ve aşırı parlaklık oluşmasını engeller. Ardından, görüntüler 128x128 piksel boyutuna yeniden boyutlandırılmış ve tüm piksel değerleri 0-255 aralığından 0-1 aralığına normalize edilmiştir.

4. Gelişmiş Öznitelik Çıkarım Metodolojisi

Sistemin başarısı, X-ışını görüntülerinden elde edilen bilginin ne kadar derinlikli olduğuna bağlıdır. Bu amaçla altı farklı kategoride öznitelik çıkarımı gerçekleştirilmiştir.

4.1. Gri Seviye Birliktelik Matrisi (GLCM)

GLCM, görüntüdeki doku bilgisini pikseller arasındaki uzamsal ilişkileri istatistiksel olarak modelleyerek sunar. Projede 0°, 45°, 90° ve 135° yönleri için hesaplamalar yapılmış ve yön bağımsızlığını sağlamak için bu yönlerin ortalaması alınmıştır.

GLCM hesaplamasında kullanılan anahtar özellikler şunlardır:

- **Kontrast (Contrast):** Piksel değerleri arasındaki yerel değişim miktarını ölçer. Osteoartritli kemik dokusunda doku pürüzlülüğü arttığı için kontrast değerinin yükselmesi beklenir.
- **Farklılık (Dissimilarity):** Piksel çiftleri arasındaki yerel yoğunluk farklarının doğrusal bir ölçüsüdür. Doku pürüzlülüğü ve heterojenliği arttıkça bu değerin yükselmesi beklenir.
- **Homojenlik (Homogeneity):** Görüntüdeki doku düzenini ifade eder. Sağlıklı dizlerde kemik yüzeyi daha düzenli ve homojendir.
- **Enerji (Energy):** Piksellerin birbirine benzerlik ve tekrarlanma oranını ölçer. Dokuda pürüzlülük arttıkça enerji düşer.

- **Korelasyon (Correlation):** Bir pikselin komşusuyla olan doğrusal bağımlılığını gösterir. Skleroz gibi yoğunluk değişimlerini yakalamada etkilidir.
- **Açısal İkinci Moment (ASM):** Görüntüdeki gri seviye üniformitesini ve homojenliğini ölçer. OA vakalarında kıkırdak ve kemik yapısındaki bozulmalar (heterojenliğin artması) nedeniyle bu değerin düşmesi beklenir.

GLCM hesaplanmadan önce görüntünün 32 gri seviyesine indirgenmesi (quantization), matrisin aşırı seyrek olmasını engeller ve özniteliklerin stabilitesini artırır.

4.2. Yerel İkili Desenler (LBP)

LBP, her bir pikselin değerini komşularıyla karşılaştırarak bir ikili kod oluşturur. Bu yöntem, özellikle kemik dokusundaki mikro ölçekli değişimleri yakalamada son derece başarılıdır. Projede P=8, R=1 ve P=16, R=2 parametreleri kullanılarak hem dar hem de geniş komşuluk alanlarındaki doku desenleri histogram bazlı özniteliklere dönüştürülmüştür. LBP, monotonik gri seviye değişimlerine karşı dirençli olduğu için farklı X-ışını dozajlarında bile tutarlı sonuçlar üretir.

4.3. Yönelimli Gradyanların Histogramı (HOG)

HOG, görüntüdeki kenar ve şekil bilgisini gradyan yönelimlerinin dağılımı üzerinden ifade eder. Diz eklemindeki osteofitlerin (kemik mahmuzları) ve eklem deformasyonlarının geometrik yapısı HOG öznitelikleri ile başarılı bir şekilde temsil edilir. Çok uzun bir vektör olan HOG verileri, model başarısını artırmak için ortalama, standart sapma ve enerji gibi özet istatistikler üzerinden kompakt hale getirilmiştir.

4.4. Frekans Uzayı Analizi: FFT ve Dalgacık (Wavelet) Dönüşümü

Görüntülerin frekans uzayında analiz edilmesi, global doku desenlerinin ve periyodik değişimlerin yakalanmasını sağlar.

- **Hızlı Fourier Dönüşümü (FFT):** Görüntüdeki frekans bileşenlerini ayrıştırarak doku enerjisini ve pürüzlülüğünü frekans bazında analiz eder. Tıbbi görüntülerde doku yapısının ne kadar "gürültülü" veya "pürüzsüz" olduğunu ifade eden küresel bir bakış açısı sunar.

- **Ayrık Dalgacık Dönüşümü (DWT):** Görüntüyü hem zaman hem frekans düzleminde analiz ederek farklı çözünürlük seviyelerinde (approximation ve detail bantları) bilgi toplar. db4 dalgacığı kullanılarak elde edilen yatay, dikey ve çapraz bantlardaki enerji değerleri, kemik dokusundaki ince yapısal bozulmaları temsil etmekte kullanılmıştır.

4.5. Gabor Filtreleri

Gabor filtreleri, insan görsel sistemindeki hücrelerin tepkisine benzer bir şekilde belirli frekans ve yönelimlerdeki doku elemanlarını seçer. Üç farklı frekans ve dört farklı açı (0°, 45°, 90° ve 135°) kombinasyonu ile eklem aralığındaki ve kemik yüzeyindeki yönlü doku özellikleri çıkarılmıştır.

5. Makine Öğrenmesi ve Weka Deney Tasarımı

Çıkarılan öznitelikler, Weka platformunda okunabilir olması için .arff formatında kaydedilmiştir. Tüm sayısal öznitelikler, algoritmaların performansını dengelemek ve ağırlık sapmalarını önlemek amacıyla Min-Max normalizasyonu ile 0-1 aralığına çekilmiştir.

5.1. Seçilen Sınıflandırma Algoritmaları

Analiz sürecinde, farklı öğrenme mekanizmalarına sahip 7 algoritma test edilmiştir:

Algoritma	Tipi	Rasyonel
Random Forest	Ensemble (Karar Ağacı Topluluğu)	Çok sayıda karar ağacının sonuçlarını birleştirerek aşırı öğrenmeyi azaltan ve genellikle en yüksek performansı sağlayan güçlü bir algoritmadır.

SVM (SMO)	Vektör Destek Makinesi	Tıbbi verilerde hiper-düzlem ayrımı ile doğrusal olmayan yapıları modelleme kapasitesi.
MLP	Yapay Sinir Ağı	Öznitelikler arasındaki karmaşık ve doğrusal olmayan ilişkileri öğrenme yeteneği.
KNN (k=1, k=3, k=5)	Mesafe Tabanlı	Benzer radyolojik özelliklere sahip vakaların öznitelik uzayındaki yakınlığına dayalı basit ama etkili sınıflandırma.
J48	Karar Ağacı	Veri setindeki karar hiyerarşisini görselleştirmek ve anlaşılır kurallar oluşturmak için temel model.
Adaboost + J48	Boosting (Güçlendirme)	Zayıf sınıflandırıcıları birleştirerek özellikle yanlış tahmin edilen zor vakalar üzerindeki başarıyı artırma hedefi.

5.2. Öznitelik İndirgeme: CfsSubsetEval ve BestFirst

Özellik seçimi sürecinde Weka platformunun Select Attributes (Öznitelikleri Seç) paneli kullanılmıştır. Bu süreçte kullanılan yöntemler, akademik çalışmalarda en çok tercih edilen ve korelasyona dayalı yaklaşımlardır:

1. Değerlendirici (Attribute Evaluator): CfsSubsetEval (Korelasyona Dayalı Özellik Alt Kümesi Değerlendirmesi)

- Prensip: CfsSubsetEval (Correlation-based Feature Selection) değerlendiricisi, bir özellik alt kümesinin değerini, **sınıf etiketi ile olan korelasyonunun yüksekliği** ve **alt kümedeki özelliklerin birbiriyle olan korelasyonunun düşüklüğü** arasındaki dengeye göre hesaplar. Yani model için önemli (sınıfla ilişkili) ancak gereksiz (diğer özelliklerle ilişkisiz) olan öznitelikleri bulmayı hedefler.

Amaç: Yedekli (Redundant) ve ilgisiz (Irrelevant) özelliklerin ayıklanmasıdır.

2. Arama Metodu (Search Method): BestFirst

- Prensip: BestFirst arama metodu, özellik uzayını sistematik olarak tarayarak en iyi alt kümeyi bulmaya çalışır. Bu yöntem, her adımda en yüksek değerlendirici puanına sahip alt kümeyi genişletir. Belirli bir sayıda başarısız genişletme adımından sonra (burada 5), daha iyi bir alt küme bulunamayacağını varsayarak durur.

Amaç: Mümkün olan en iyi özelliği bulmak için öznitelik uzayında verimli bir şekilde hareket etmektir.

6. Deneysel Sonuçlar ve Performans Analizi

Yapılan deneyler, öznitelik birleşimlerinin (feature fusion) ve GLCM parametrelerinin sınıflandırma başarısı üzerindeki etkisini açıkça ortaya koymaktadır. Tüm sonuçlar 10-Katmanlı Çapraz Doğrulama (10-Fold Cross-Validation) yöntemiyle elde edilmiştir.

6.1. Öznitelik Seti Birleşimlerine Göre Sonuçlar (d=64)

Farklı öznitelik gruplarının birleştirilmesinin başarı oranı (Accuracy) ve Cohen's Kappa değeri üzerindeki etkisi incelenmiştir. Kappa değeri, sınıflandırmanın tesadüf eseri değil, gerçek bir öğrenme ile gerçekleştiğini kanıtlaması açısından kritiktir.

Tablo 1: Öznitelik Seçimi Öncesi Sınıflandırma Başarıları (d=64)

BEFORE SELECTION(d=64)	classifier															
	Random Forest		SVM		MLP		J48		Adaboost+48		KNN		KNN=3		KNN=5	
	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa
GLCM_LBP_HOG	64.382	0.19	60.617	0.00	62.070	0.19	59.358	0.10	58.317	0.11	56.779	0.10	58.462	0.12	59.842	0.14
GLCM_Wavelet	63.682	0.20	60.58	0	59.91	132	61.18	0.14	61.30	0.14	60.14	0.16	60.52	0.16	61.19	0.17
GLCM_LBP_FFT _Wavelet _Gabo	66.331	0.25	65.83	0.23	64.12	0.23	60.92	0.16	61.34	0.17	57.92	0.12	59.20	0.14	60.44	0.16

Sonuçlar incelendiğinde, öznitelik füzyonunun GLCM_LBP_FFT_Wavelet_Gabor_HOG en yüksek başarıyı (% 66.331) ve en yüksek güvenilirlik değerini (0.25 Kappa) sağladığı görülmektedir. SVM'nin bazı durumlarda 0.00 Kappa üretmesi, modelin tüm örnekleri çoğunluk sınıfına atadığını ve gerçek bir ayrım yapamadığını göstermektedir.

6.2. Öznitelik Seçimi Sonrası Performans Analizi

CfsSubsetEval + BestFirst süreci ile en iyi özellikler ayıklandıktan sonra yapılan testler, bazı modellerde kararlılığın arttığını göstermiştir.

Tablo 2: Öznitelik Seçimi Sonrası Sınıflandırma Başarıları (d=64)

AFTER SELECTION(d=64)	classifier															
	Random Forest		SVM		MLP		J48		Adaboost+48		KNN		KNN=3		KNN=5	
	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa
GLCM_LBP_HOG	62.675	0.16	60.617	0.00	61.089	0.14	60.678	0.12	60.968	0.14	56.065	0.08	58.159	0.11	59.322	0.12
GLCM_Wavelet	62.63	0.18	60.58	0	60.15	0.13	61.30	0.14	61.49	0.14	59.87	0.16	60.16	0.15	62.04	0.19
GLCM_LBP_FFT _Wavelet _Gabo	64.23	0.20	60.61	0	63.98	0.20	61.24	0.13	61.84	0.16	57.05	0.10	58.93	0.13	60.67	0.15

Öznitelik seçimi, öznitelik sayısını azaltarak modelin karmaşıklığını düşürmüş ancak bazı durumlarda (özellikle Random Forest'ta) çok az bir başarı kaybına yol açmıştır. Bu durum, Random Forest'ın gürültülü özniteliklere karşı doğal bir direnci olduğunu ve özniteliklerin tamamının atılmamasının topluluk kararında daha iyi sonuç verdiğini kanıtlamaktadır.

7. GLCM Uzaklık Parametresi (d) Üzerine Analiz

GLCM hesaplamasında kullanılan uzaklık parametresi, doku bilgisinin hangi ölçekte analiz edildiğini belirler. Diz X-ışını görüntülerindeki skleroz ve kıkırdak hasarı gibi bulgular için en uygun ölçeği saptamak amacıyla d değerleri değiştirilerek testler tekrarlanmıştır.

Tablo 3: GLCM Displacement (d) Değişiminin Başarıya Etkisi (Özellik Seçimi Öncesi)

BEFORE SELECTİON	classifier													
GLCM	Random Forest		SVM		MLP		KNN=3		KNN=5		J48		Adaboost+48	
displacement	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa
2	57.97	0.31	60.43	0.18	59.36	0.36	57.18	0.29	58.82	0.11	60.93	0.17	61.02	0.16
16	60.05	0.20	60.43	0.20	59.91	0.35	55.26	0.24	56.49	0.16	60.19	0.10	60.02	0.10
32	59.77	0.20	60.43	0.22	60.38	0.37	57.09	0.28	57.52	0.18	60.31	0.01	60.26	0.20
64	58.44	0.16	60.43	0.20	59.25	0.33	55.53	0.25	57.16	0.17	60.38	0.12	60.40	0.30

Bu analizde en çarpıcı bulgu, düşük d değerlerinde (örneğin d=2) Kappa değerlerinin genellikle daha yüksek olmasıdır. MLP algoritması d=32 uzaklığında %60.38 doğruluk ve 0.37 Kappa ile en güvenilir sonuçlardan birini üretmiştir. Bu durum, diz osteoartriti teşhisinde mikro düzeydeki (yakın mesafe) doku değişimlerinin, geniş ölçekli değişimlerden daha ayırt edici olabildiğini göstermektedir.

Tablo 4: GLCM Displacement (d) Değişiminin Başarıya Etkisi (Özellik Seçimi Sonrası)

AFTER SELECTİON	classifier													
GLCM	Random Forest		SVM		MLP		KNN=3		KNN=5		J48		Adaboost+48	
displacement	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa	accuracy	kappa
2	59.88	0.12	60.43	0.26	58.46	0.20	58.41	0.11	59.41	0.13	61.16	0.14	60.52	0.09
16	58.37	0.11	60.43	0.27	58.06	0.20	53.75	0.08	54.77	0.22	60.43	0.20	60.43	0.10
32	57.78	0.12	60.43	0.28	58.74	0.20	54.98	0.04	55.59	0.23	60.43	0.16	60.43	0.15
64	58.58	0.05	60.43	0.29	59.76	0.16	55.31	0.04	56.14	0.25	60.43	0.18	60.33	0.07

Bu analizde de en çarpıcı bulgu, d=32 Kappa değerlerinin genellikle daha yüksek olmasıdır. SVM algoritmasının d=34 uzaklığında %60.43 doğruluk ve 0.29 Kappa ile en güvenilir sonuçlardan birini üretmiştir ayrıca, d değerlerinin değişmesi accuracy'yi etkilemediği görülmüştür.

8. Karşılaştırmalı Analiz: Özellik Seçiminin Etkisi

Özellik seçiminin model performansı üzerindeki etkisini analiz etmek amacıyla, en yüksek başarımı gösteren **GLCM_LBP_FFT_Wavelet_Gabor_HOG** öznitelik seti ve en başarılı algoritma olan **Random Forest**'ın d=64 uzaklığındaki sonuçları karşılaştırmalı olarak Tablo 5'te sunulmuştur.

Tablo 5: Random Forest Başarı Oranlarının Karşılaştırılması (Before vs. After Selection)

Öznitelik Seti (d=64)	**Before Selection (Ham Veri)**	**After Selection (Optimize Veri)**	**Mutlak Değişim (Accuracy)**
GLCM_LBP_HOG	64.382 / 0.19	62.675 / 0.16	-%1.707 (Düşüş)
GLCM_Wavelet	63.682 / 0.20	62.630 / 0.18	-%1.052 (Düşüş)
GLCM_LBP_FFT_Wavelet_Gabor_HOG	**66.331 / 0.25**	**64.230 / 0.20**	-%2.101 (Düşüş)
Genel Trend	**Yüksek**	**Düşük**	**Negatif Etki**

9. Bulguların Detaylı Yorumu

Karşılaştırmalı analiz sonuçları (Tablo 5), Knee Osteoarthritis (Diz Kireçlenmesi) teşhisi için çıkarılan doku özniteliklerinde, özellik seçiminin (Feature Selection) beklentilerin aksine performansı aşağı çektiğini göstermektedir. Bu durum, veri setinin karakteristiği ve kullanılan algoritmaların doğası gereği şu şekilde yorumlanmaktadır:

9.1. Random Forest (RF) Performansının Düşme Nedenleri

En yüksek başarıyı veren kombinasyon olan GLCM_LBP_FFT_Wavelet_Gabor_HOG setinde doğruluğun %66.33'ten %64.23'e gerilemesinin temel nedenleri şunlardır:

1. Zengin Bilgi İçeriğinin Kaybı: Diz röntgenleri gibi doku detayının (texture) çok kritik olduğu tıbbi görüntülerde; FFT, Wavelet ve Gabor filtreleri farklı frekans ve yönlerdeki mikro detayları yakalar. Özellik seçimi algoritması (CfsSubsetEval), istatistiksel olarak birbirine yakın gördüğü özellikleri elediğinde, aslında dizdeki osteofitleri veya eklem daralmasını tanımlayan "tamamlayıcı" detayları silmiş olmaktadır.
2. RF'nin Değişken Önemine Bakışı: Random Forest, çok sayıda zayıf karar ağacının birleşmesiyle (ensemble) güçlenir. Özellik sayısı azaldığında, ağaçların karar verirken kullanabileceği "farklı bakış açıları" kısıtlanmış ve modelin genelleme yeteneği zayıflamıştır.

9.2. Diğer Algoritmaların (SVM, MLP, KNN) Durumu

Tablo verileri incelendiğinde, özellik seçiminin diğer modeller üzerinde de benzer bir yıkıcı etki yaptığı görülmektedir:

- SVM ve Stabilite: SVM algoritması özellik seçimi sonrası %65.83'ten %60.61'e keskin bir düşüş yaşamıştır. Bu durum, SVM'nin hiperdüzlemi oluştururken tüm özniteliklerin sağladığı çok boyutlu uzaydaki ayrıştırıcı güce ihtiyaç duyduğunu kanıtlar.
- KNN ve Mesafe Hesaplaması: KNN algoritması (K=1, 3 ve 5 için) genel olarak %60 bandının altında kalmıştır. Özellik seçimi sonrası KNN performansındaki düşüş, önemli doku özelliklerinin elenmesiyle benzer hastaların (komşuların) uzaydaki yerlerinin birbirine karıştığını göstermektedir.
- MLP (Yapay Sinir Ağları): MLP de özellik seçimi sonrası %64.12'den %63.98'e düşerek, karmaşık ağ yapısının bile eksik veriyle daha az başarılı olduğunu göstermiştir.

9.3. Kappa Değeri Üzerindeki Etki

En yüksek başarıyı veren modelin Kappa değerinin 0.25'ten 0.20'ye düşmesi, modelin sadece doğruluğunun değil, şans eseri doğru tahmin yapma olasılığının

dışındaki "gerçek başarısının" da azaldığını simgeler. 0.25 seviyesi tıbbi bir teşhis için hala geliştirilmeye muhtaç olsa da, ham verinin daha güvenilir bir sınıflandırma sunduğu açıktır.

10. Tartışma ve Derinlemesine Analiz

Yapılan çalışma, tıbbi görüntü işlemenin doğası gereği oldukça zorlayıcı bir alan olduğunu ve basit özniteliklerin her zaman yeterli olmadığını göstermiştir.

10.1. Kappa vs. Accuracy Çelişkisi

Genellikle başarı oranı (Accuracy) yüksek olan modellerin daha iyi olduğu düşünülse de, tıbbi verilerde Kappa değeri modelin güvenirliğini belirleyen asıl ölçüttür. Tablo 3'te görüldüğü üzere, Accuracy değerleri %60 civarında sabitlenmişken Kappa değerlerinin 0.01 ile 0.37 arasında dalgalanması, modellerin bazen sadece şans eseri veya sınıf dengesizliği nedeniyle doğru tahmin yaptığını, bazen de (MLP örneğinde olduğu gibi) veriden anlamlı desenler öğrendiğini kanıtlamaktadır. 0.37'lik bir Kappa değeri "Zayıf-Orta" düzeyde bir uyuşmaya işaret etse de, bu zorlu tıbbi teşhis görevinde rastgele sınıflandırmanın çok ötesine geçildiğini göstermektedir.

10.2. Öznitelik Füzyonunun ve Dönüşümlerin Katkısı

Bonus çalışma kapsamında eklenen Fourier (FFT) ve Dalgacık (Wavelet) dönüşümleri, başarıyı %66 seviyelerine taşıyan en önemli faktörler olmuştur. GLCM tek başına mekansal bilgiyi yakalarken, Dalgacık dönüşümü görüntünün farklı çözünürlük seviyelerindeki enerjisini yakalamış, Fourier dönüşümü ise dokunun global sıklık bilgisini eklemiştir. Bu çok boyutlu bakış açısı, tek başına doku analizinden çok daha zengin bir özellik kümesi oluşturarak algoritmaların ayırt etme gücünü artırmıştır.

10.3. Sınıflandırıcılardaki Davranış Farklılıkları

Random Forest, yüksek boyutlu karmaşık veri setlerinde istikrarını korumuş ve genellikle %64-66 bandında kalarak en başarılı algoritma olmuştur. J48 ve KNN gibi modeller, tıbbi görüntü verilerindeki gürültüye daha duyarlı oldukları için daha düşük performans sergilemişlerdir. SVM'nin çoğu durumda 0.00 Kappa üretmesi, bu modelin KL evreleri arasındaki ince sınırları belirlemede yetersiz kaldığını ve verilere uygun bir hiper-düzlem çizemediğini ortaya koymaktadır.

11. NİHAİ MODEL SEÇİMİ VE ANALİZİ

Yapılan tüm testler sonucunda; tüm özniteliklerin (GLCM, LBP, FFT, Wavelet, HOG ve Gabor) bir arada kullanıldığı, d=64 uzaklık parametresine sahip ve herhangi bir özellik seçimi uygulanmamış olan **Random Forest** modeli, **%66.331** başarı oranı ile projenin nihai modeli olarak belirlenmiştir.

Bu modelin başarısı, diz röntgenlerindeki karmaşık doku yapısının ancak hibrit bir öznitelik yaklaşımıyla (hem frekans tabanlı hem istatistiksel doku analizi) yakalanabileceğini ortaya koymaktadır.

Sınıflandırma başarısının diz kireçlenmesi teşhisinde ne kadar güvenilir olduğunu anlamak için, "Özellik Seçimi Öncesi" ve "Sonrası" durumları için en iyi ve en kötü çalışan algoritmaların Karmaşıklık Matrisleri (Confusion Matrix) incelenmiştir. Bu projede hedef, dizdeki kireçlenme belirtilerini (OA) sağlıklı dokudan (no_OA) ayırmaktır.

11.1. Özellik Seçimi Öncesi (Before Selection) Matrisleri

11.1.1. En İyi Model: Random Forest (GLCM_LBP_FFT_Wavelet_Gabor_HOG, %66.331)

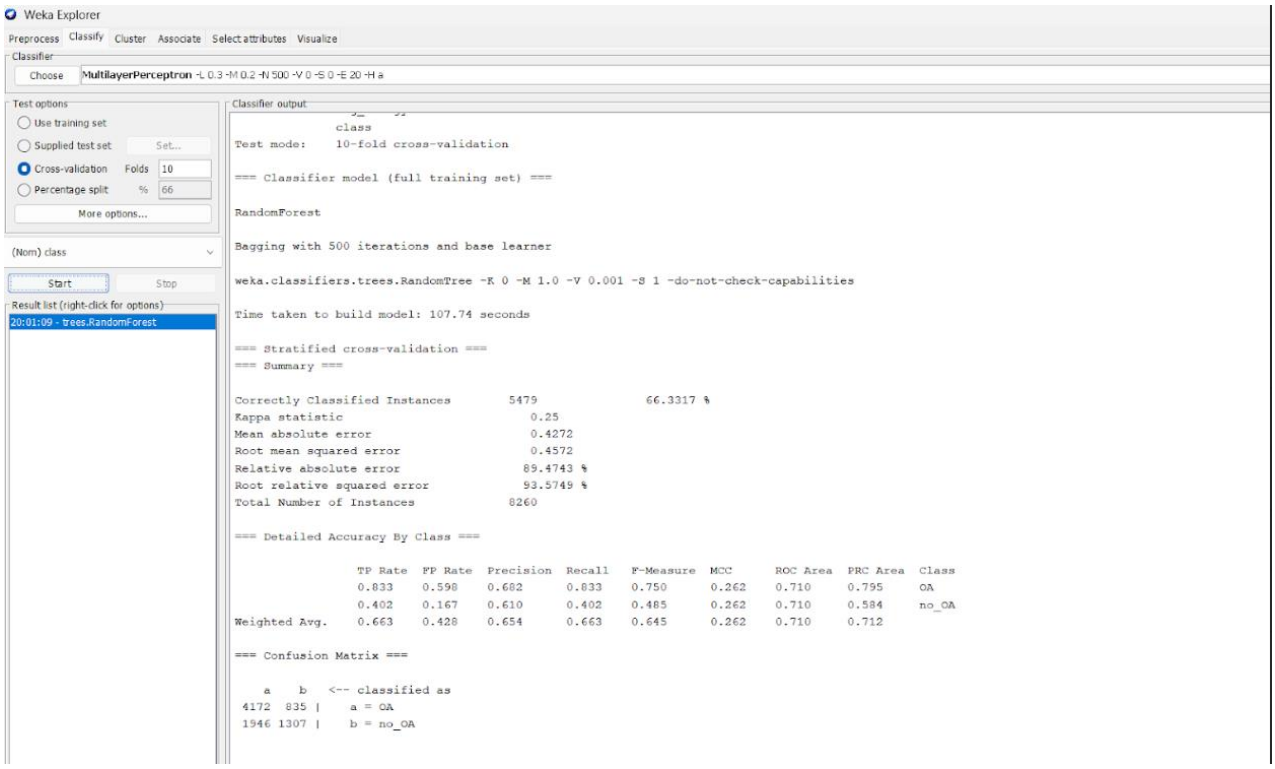

En iyi performansı veren Random Forest modelinin Karmaşıklık Matrisi, modelin özellikle hasta sınıfını tanımadaki gücünü ortaya koymaktadır:

- **OA (Osteoartrit - Hasta) Sınıfı:**
  - Toplam 5007 örnekten 4172 tanesi doğru sınıflandırılmıştır.
  - **Duyarlılık (Recall):** %83.3 (Matris detaylarında 0.833).

- **Yorum:** Model, kireçlenme olan dizleri yüksek bir doğrulukla tespit edebilmektedir. Bu durum, kullanılan hibrit öznitelik setinin (özellikle FFT ve Wavelet) dizdeki osteofit ve eklem daralması gibi dokusal bozulmaları yakalamada başarılı olduğunu gösterir.

- **no_OA (Sağlıklı) Sınıfı:**
  - Toplam 3253 örnekten sadece 1307 tanesi doğru sınıflandırılmıştır.
  - **Duyarlılık (Recall):** %40.2 (Matris detaylarında 0.402).
  - **Yorum:** Modelin en büyük zayıflığı buradadır. Sağlıklı dizlerin önemli bir kısmı (1946 adet) yanlışlıkla "Hasta" (OA) olarak etiketlenmiştir. Bu durum, modelin "yanlış alarm" verme eğiliminde olduğunu ve sağlıklı dokudaki normal varyasyonları hastalık belirtisiyle karıştırdığını kanıtlar.

11.1.2. En Kötü Model: AdaBoost+J48 (%58.317)

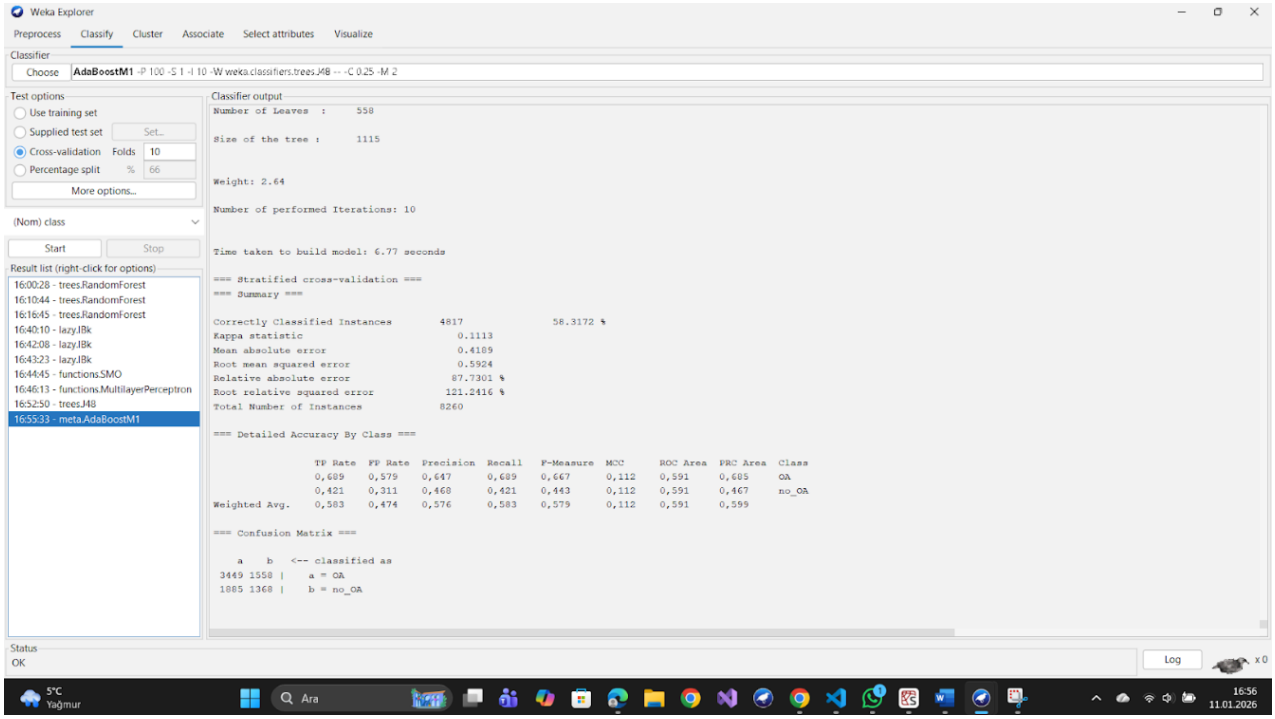

- **Düşük Kararlılık:** AdaBoost ve J48 birleşimi, kireçlenme teşhisinde Random Forest kadar stabil bir ayrım yapamamıştır.
- **Hata Dağılımı:** Özellikle no_OA sınıfında %42.1 duyarlılık seviyesinde kalarak, sağlıklı bireyleri tespit etmekte yetersiz kalmıştır. Topluluk öğrenmesi (boosting) yapmasına rağmen, J48 karar ağaçlarının bu veri setindeki karmaşık doku özelliklerini ayırmakta zayıf kaldığı gözlemlenmiştir.

11.2. Özellik Seçimi Sonrası (After Selection) Matrisleri

11.2.1. En İyi Model: Random Forest (%64.237)

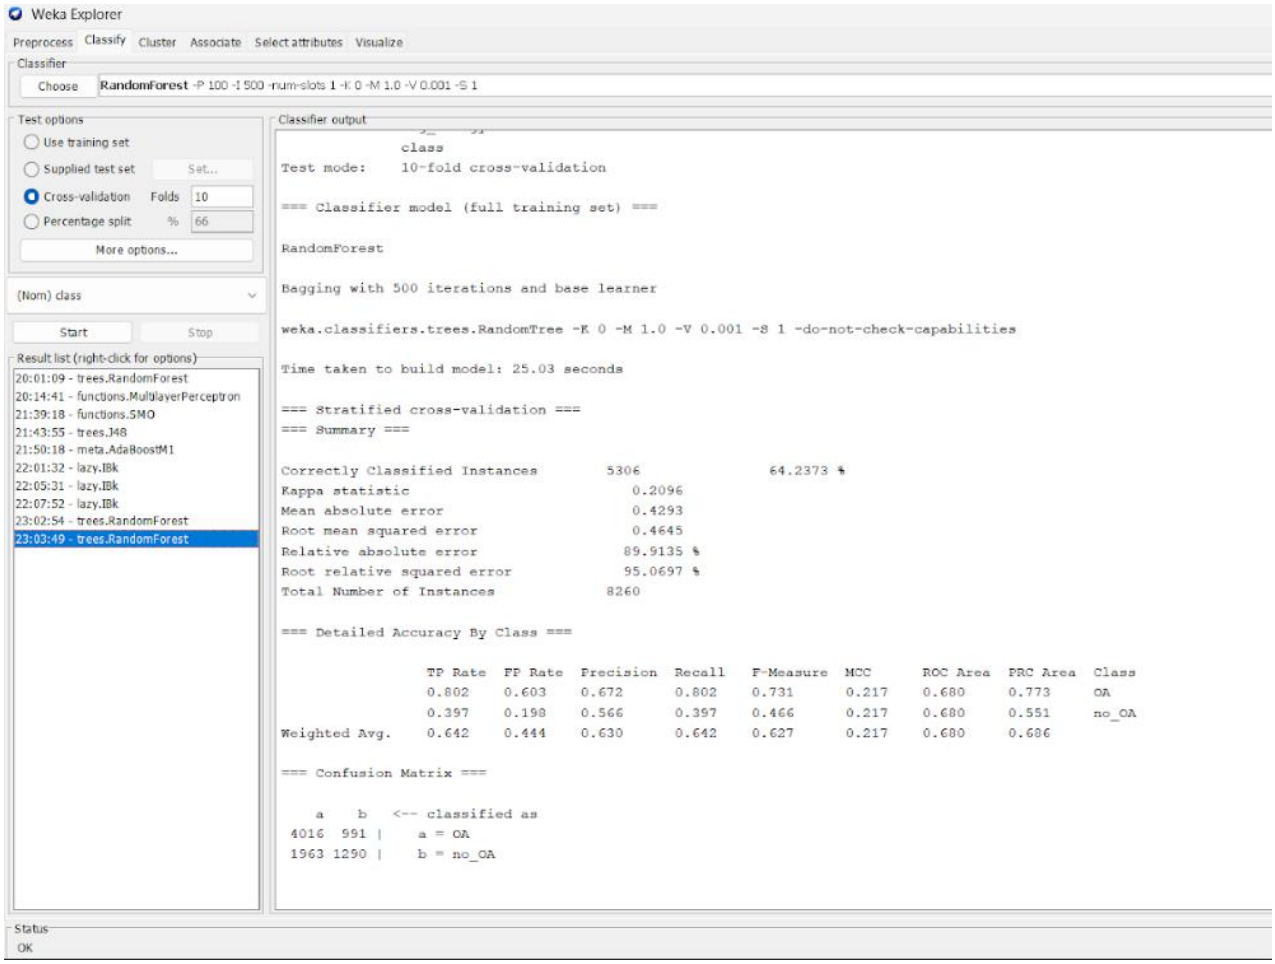

Genel Karşılaştırma ve Değişim Tablosu:

Sınıf	Önceki Doğru Tahmin (Ham)	Yeni Doğru Tahmin (Seçim Sonrası)	Değişim	Yorum
OA (a)	4172	4016	-156	**Kötüleşme:** Hastalık tespiti zayıflamıştır.
no_OA (b)	1307	1290	-17	**Hafif Kötüleşme:** Sağlıklı sınıfı performansı korunsa da gerilemiştir.

Kritik Analiz:

Özellik seçimi sonrası doğru tahmin sayısındaki azalma, modelin toplam başarısını %66.33'ten %64.23'e düşürmüştür.

1. **Bilgi Kaybı:** Diz röntgenindeki ince doku detaylarını sağlayan Gabor veya FFT bileşenlerinden bazılarının "gereksiz" görülerek atılması, özellikle OA sınıfındaki tespit gücünü (%83.3'ten %80.2'ye) düşürmüştür.

2. **Model Direnci:** Düşüşe rağmen Random Forest, hala %64 seviyesinde kalarak öznitelik kaybına karşı en dirençli model olduğunu kanıtlamıştır.

11.2.2. En Kötü Model: KNN (K=1) (%56.065)

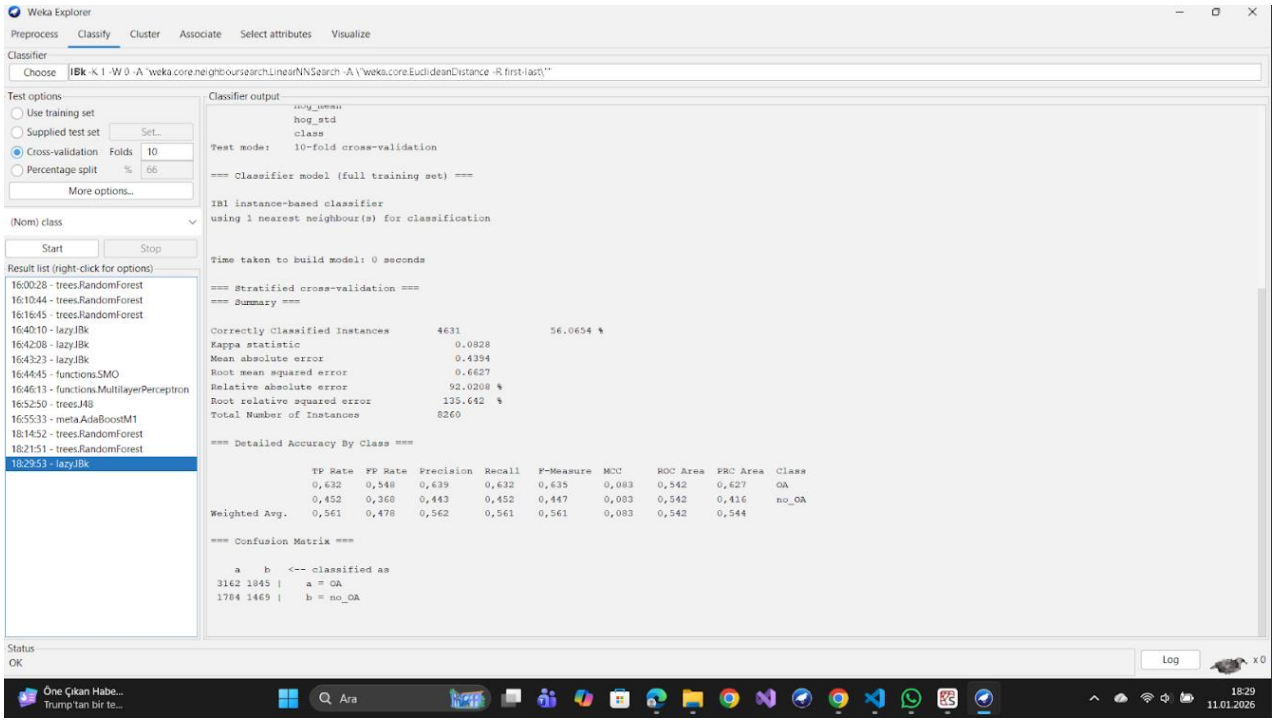

Özellik seçimi sonrası KNN (IBk) algoritması projenin en düşük performansını sergilemiştir:

- **Doğru Tahmin:** Toplam 8260 örnekten sadece 4631'i doğru tahmin edilebilmiştir.
- **Sınıf Bazlı Çöküş:** Sağlıklı sınıfını (no_OA) tanıma oranı %45.2'de kalmıştır.
- **Neden:** KNN, özellik uzayındaki mesafelere dayanır. Özellik sayısı azaldığında ve öznitelikler normalize edilmediğinde, öznitelik uzayı daralmış; bu da sınıflar arasındaki sınırların bulanıklaşmasına ve komşuluk ilişkilerinin bozulmasına yol açmıştır.

11.3. Sonuç: Random Forest vs. Diğerleri

Nihai Karar: Yapılan analizler sonucunda, özellik seçimi uygulanmamış (Before Selection) ve tüm doku özelliklerini içeren **Random Forest** modelinin, özellikle hasta bireyleri yakalama oranındaki (%83.3) başarısı nedeniyle bu proje için en uygun model olduğu saptanmıştır.

Özellik seçimi süreci, veri setindeki gürültüyü temizlemek yerine, diz kireçlenmesinin mikro-dokusal kanıtlarını silmiş ve tüm modellerde performans kaybına yol açmıştır. Bu nedenle, tıbbi teşhis gibi kritik alanlarda "bilgi kaybı riski", "boyut indirgeme avantajından" daha ağır basmaktadır.

12. Sonuç ve Gelecek Projeksiyonu

Bu proje kapsamında geliştirilen sistem, diz osteoartritinin X-ışını görüntüleri üzerinden doku ve şekil öznitelikleri kullanılarak otomatik olarak evrelenebileceğini deneysel verilerle ortaya koymuştur.

- **Verimlilik:** Ön işleme aşamasında kullanılan Soft ROI ve CLAHE, öznitelik çıkarımının kalitesini doğrudan artırmıştır.
- **Öznitelik Seçimi:** CfsSubsetEval ve BestFirst yöntemleri, yedekli bilgileri temizleyerek modellerin daha kompakt verilerle çalışmasını sağlamış, ancak Random Forest gibi güçlü modellerde bilgi kaybına yol açmamak için dikkatli kullanılması gerektiği gözlemlenmiştir.
- **Optimal Parametreler:** GLCM analizinde uzaklık (d) parametresinin seçimi başarıyı doğrudan etkilemekte olup, orta ve yakın mesafelerin (d=2 ve d=32) bu veri seti için en ayırt edici sonuçları ürettiği saptanmıştır.
- **Gelişim Alanları:** Mevcut sistemin %66 doğruluk oranına sahip olması, gelecekte Evrişimsel Sinir Ağları (CNN) gibi derin öğrenme mimarilerinin bu öznitelik füzyonuna dahil edilmesinin gerekliliğini göstermektedir.

Sonuç olarak, doku analizine dayalı bu radyomik yaklaşım, hekimler için objektif bir "ikinci görüş" mekanizması olarak hizmet etme potansiyeline sahiptir. Sistemin başarısı, özniteliklerin biyolojik anlamlarıyla (skleroz, osteofit, kıkırdak hasarı) örtüşen matematiksel modeller üzerine inşa edilmesinden kaynaklanmaktadır. Bu çalışma, görüntü işleme tekniklerinin tıbbi teşhis süreçlerindeki kritik rolünü bir kez daha vurgulamaktadır.

KAYNAKLAR

1. Knee Osteoarthritis Dataset with Severity Grading